

Agent 评估手册（PDF 样例）

为什么评估

没有评估的 Agent 改进是盲目的。每次修改提示词或工具，都需要在同一组测试用例上重新打分，才能知道改动是变好还是变坏。

评估集

评估集是一组带标准答案的测试用例。用例要覆盖典型路径、边界情况和历史回归问题。用例数量不必多，但要稳定。

评分方式

可以用关键词命中做确定性评分，也可以用 LLM 当裁判做语义评分。确定性评分成本低、可复现；裁判评分覆盖面广但有噪声。